# Note de synthèse : performances Charades dans VideoGLUE

Yuan et al., TMLR 2024 — Tables 3 à 6

https://arxiv.org/abs/2307.03166

Asma
*Superviseur : Prof. Éric Hervet*
*Alliance Canada — projet Mitacs*

15 juillet 2026

**Abstract**

Cette note répond à la demande d'un résumé des performances Charades des fondation models (FMs) évalués dans VideoGLUE (CLIP, FLAVA, CoCa, DINOv2, VATT, VideoMAE, InternVideo), avec leurs caractéristiques principales et les ressources / coûts rapportés. **Oui :** dans la Table 5 (MLAP), **58.2 mAP** est le meilleur résultat Charades parmi les FMs, obtenu par **VATT**.

## 1 Contexte

VideoGLUE [1] évalue sept FMs sur huit jeux vidéo (dont Charades, classification multi-label) sous quatre méthodes d'adaptation. La Figure 1 du papier est un radar *normalisé* (sans chiffres bruts) ; les scores Charades (mAP) sont dans les Tables 3–6.

**Charades (VC-ML) :** ∼30 s / vidéo, plusieurs actions simultanées, ∼7 811 train / 1 814 test, 157 classes [2].

## 2 Caractéristiques principales des modèles

Tous les FMs sont volontairement évalués en **ViT-B** [3] pour aligner l'architecture et le coût relatif (Section 3.1).

Table 1: Fondation models étudiés (d'après Table 1, VideoGLUE).

| Modèle | Modalité pretrain | Données | Objectif |
|---|---|---|---|
| CLIP | Image + texte | WebImageText | Contrastif |
| FLAVA | Image + texte | PMD | Contrastif + MIM + MLM |
| CoCa | Image + texte | JFT-3B + ALIGN | Contrastif + captioning |
| DINOv2 | Image | LVD-142M | MIM + DINO |
| VideoMAE | Vidéo | Kinetics-400 | Masked video modeling |
| InternVideo | Vidéo | UnlabeledHybrid | MVM + contrastif |
| VATT | Vidéo + audio + texte | HowTo100M | Contrastif |

**Image-native :** CLIP, FLAVA, CoCa, DINOv2. **Video-native :** VideoMAE, InternVideo, VATT.

**Méthodes d'adaptation (Tables 3–6)**

- **Table 3 — End-to-end (E2E) :** tout le ViT-B + tête entraînés.
- **Table 4 — Frozen :** backbone gelé ; une couche de cross-attention / pooler entraînée.
- **Table 5 — MLAP :** multi-layer attention pooler (plusieurs features gelées, pooler hiérarchique entraîné).
- **Table 6 — LoRA / low-rank adapter :** backbone gelé ; adapters + tête entraînés.

# 3 Performances Charades (mAP)

Table 2: mAP Charades (%). Chiffres extraits des Tables 3–6 de VideoGLUE. Le meilleur FM par colonne est en gras.

| Modèle | Table 3 E2E | Table 4 Frozen | Table 5 MLAP | Table 6 LoRA |
|---|---|---|---|---|
| CLIP | 54.3 | 11.2 | 41.5 | 44.2 |
| FLAVA | 48.6 | 12.6 | 38.2 | 40.8 |
| CoCa | 55.0 | 8.8 | 19.6 | 45.8 |
| DINOv2 | 52.4 | 25.8 | 47.8 | 38.0 |
| **VATT** | **55.7** | **33.3** | **58.2** | **53.5** |
| VideoMAE | 51.4 | 11.3 | 35.9 | 43.0 |
| InternVideo | 52.2 | 13.0 | 40.5 | 46.2 |

**Réponse à la question Table 5.** Oui : **58.2 %** est le **meilleur score Charades parmi les sept FMs**, obtenu par **VATT** avec MLAP. C'est même le meilleur score Charades FM toutes tables confondues (au-dessus de VATT E2E 55.7 et VATT LoRA 53.5).

**Lectures utiles.**

- En E2E, VATT et CoCa dominent Charades ; VideoMAE atteint 51.4.
- Sous backbone gelé (Table 4), les FMs image-native s'effondrent souvent sur Charades ; VATT reste nettement devant (33.3).
- MLAP (Table 5) récupère beaucoup pour CLIP/DINOv2, et porte VATT à 58.2.
- Video-native FMs sont en général meilleurs sur Charades quand le backbone est peu ou pas mis à jour (motion + multi-label).

# 4 Ressources et coûts

## 4.1 Ce que VideoGLUE *ne* reporte *pas*

Le papier **ne publie pas** le nombre exact de GPUs, ni la mémoire vidéo (VRAM) par carte, pour les runs des Tables 3–6. L'infra est celle d'une équipe Google DeepMind ; on peut seulement inférer un entraînement **multi-GPU** à partir du protocole (batch 256, ViT-B vidéo).

## 4.2 Ce qui est reporté (protocole Charades + Fig. 3)

**Nombre de paramètres du backbone :** ViT-B/16 standard $\approx$ **86 M** paramètres (ordre de grandeur ; partagé par les sept FMs). En E2E, $\sim$89 M entraînables incluent backbone + tête.
**VRAM / GPUs :** non spécifiés. Un batch de 256 avec ViT-B et clips spatio-temporels nécessite typiquement une agrégation multi-GPU (ou accumulation de gradients).

Table 3: Hyperparamètres Charades (Appendix D / Table 10).

| Paramètre | Valeur |
|---|---|
| Architecture | ViT-B (tous les FMs) |
| Batch size | 256 |
| Training epochs | 50 |
| Longueur de séquence ViT | $8 \times 14 \times 14$ tokens |

Table 4: Coûts d'adaptation approximatifs (Fig. 3) : paramètres entraînables et FLOPs d'inférence. Les auteurs notent que, ViT-B + même longueur de séquence ⇒ coûts quasi identiques entre FMs pour une méthode donnée.

| Méthode d'adaptation | Params entraînables (approx.) | Inference FLOPs (approx.) |
|---|---|---|
| Frozen (head seule) | ∼0.13 M | ∼367 B |
| MLAP | ∼3.7 M | ∼367 B |
| Low-rank adapter (LoRA) | ∼9.7 M | ∼370–378 B |
| End-to-end finetuning | ∼88.9 M | ∼367 B |

## References


[1] Liangzhe Yuan et al. VideoGLUE: Video General Understanding Evaluation of Foundation Models. *Transactions on Machine Learning Research*, 2024. https://arxiv.org/abs/2307.03166.

[2] Gunnar A. Sigurdsson et al. Hollywood in Homes: Crowdsourcing Data Collection for Activity Understanding. *ECCV*, 2016.

[3] Alexey Dosovitskiy et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *ICLR*, 2021.